

DOSSIER DE SYNTHÈSE DE PROJET

FOOTBALL IQ ASSISTANT

Assistant Tactique Propulsé par un Moteur RAG Hybride Local

Candidat : Adriano

Objectif : Présentation Projet & Architecture - Entretien Technique

Date : Juillet 2026

Version : MVP V1 & Roadmap V2 PRO

1. Présentation Générale & Architecture MVP

Football IQ Assistant est un assistant conversationnel spécialisé dans l'analyse tactique du football. Il permet de répondre à des requêtes complexes en s'appuyant exclusivement sur un corpus de **24 documents tactiques** originaux (268 chunks indexés) couvrant les structures de jeu, le pressing, les transitions et les rôles modernes. Il offre trois profils de réponses adaptés (Coach, Analyste et Fan) et intègre un fallback hors-ligne local.

L'Architecture Logique du RAG (MVP V1)

Composant	Détails Techniques & Solutions Retenues
Ingestion & ETL	Découpage des documents Markdown via MarkdownHeaderSplitter pour préserver la structure hiérarchique. Métadonnées YAML enrichies (Topic, Intent, Phase, Level) extraites de manière déterministe pour guider le RAG.
Stockage Hybride	Architecture <i>Enfant-Parent</i> persistante. Les enfants (chunks vectorisés) sont stockés dans Qdrant (en mémoire pour le mode local) pour la recherche de similarité, tandis que les parents complets sont indexés dans SQLite pour préserver le contexte sémantique global.
Moteur de Recherche	Pipeline hybride de pointe : 1. Query Rewriting : reformulation de requêtes via LLM pour le multi-querying. 2. Search Hybride : similarité cosinus (Qdrant) + recherche lexicale (BM25 custom). 3. Reranking : ordonnancement des 20 meilleurs candidats via FlashRank .
Génération	API FastAPI. Les réponses sont générées soit via OpenAI (GPT-4o-mini) avec les Structured Outputs (Pydantic stricts), soit via un mode de fallback local déterministe hors-ligne (TF-IDF + extraction directe du contexte).
Évaluation (QA)	Validation automatisée par méthodologie <i>LLM-as-a-judge</i> : - Fidélité au contexte (Faithfulness) : 9.0 / 10 (absence d'hallucinations tactiques). - Pertinence de la réponse (Relevance) : 8.5 / 10 (haute précision footballistique).

■ Audit Technique & Résolution de Bug

Découverte lors de l'audit de code : En analysant le fichier `app/api/chat.py`, il apparaissait une dépendance dynamique vers la variable `rag_engine` de `app.main`. L'initialisation de cette variable était absente dans `app/main.py`, provoquant un `ImportError` lors des appels de chat et l'échec des tests. **Résolution** : Nous avons corrigé ce bug en initialisant le singleton `rag_engine` directement dans `main.py` et stabilisé la suite de tests unitaires pour mocker les API externes. Résultat : **100% des tests sont désormais au vert (20/20 passés)**.

2. Innovation Clé : Le Retrieval Orienté Problème

Un système RAG classique souffre d'un biais lexical important appelé **TF-IDF/Vector Bias**. Dans un contexte de football, si un utilisateur pose une question comme « *Je joue en 4-3-3 mais mon équipe perd trop de ballons à la relance* », le RAG renvoie la fiche descriptive générale du système (`formation_433.md`) au lieu de la fiche apportant la solution concrète au problème (`sortie_balle.md`). Cela s'explique par le fait que les nombres de formations ont un IDF très élevé et une fréquence (TF) répétée dans les descriptifs tactiques.

Mécanique Algorithmique de la Solution Implémentée

Pour résoudre ce biais, nous avons développé un moteur de recherche structuré et sémantiquement pondéré en deux étapes :

- **1. Extraction Sémantique via le QueryClassifier** : Décomposition de la requête utilisateur en entités tactiques fines à l'aide de regex robustes et de lexiques ciblés pour isoler le *Système* (contexte secondaire) et le *Problème* / la *Phase de jeu* (l'intention principale).
- **2. Formule de Scoring Pondéré (Hybrid Weighting)** : Les chunks sont évalués en attribuant 90% du poids sémantique aux mots-clés du problème et de la phase de jeu (bonus cumulés de **+0.40** pour le problème et **+0.35** pour la phase de jeu), et seulement 10% de poids sur le système de jeu (**+0.10**).
- **3. Pénalité des Fiches Formationnelles** : Si un problème est détecté dans la requête, une pénalité sévère de **-0.50** est appliquée d'office aux documents dont le nom commence par `formation_`. Cela neutralise instantanément le biais TF-IDF et garantit que la solution opérationnelle remonte en tête du RAG.

Exemples de Comportement Rectifié (Cas de Test)

Requête Utilisateur	Comportement Standard (Biaisé)	Comportement RAG Orienté Problème
« Je joue en 4-3-3 mais mon équipe perd trop de ballons à la relance. »	<code>formation_433.md</code> ()	<code>sortie_balle.md</code> (Séance rondo positionnel de sortie de presse)
« En 3-5-2, on se fait transpercer sur les longs ballons dans le dos. »	<code>formation_352.md</code> (Rôle des pistons)	<code>sweeper_keeper.md</code> / <code>repli.md</code> (Couverture profondeur par le gardien-libéro)
« Mon équipe en 4-4-2 se fait aspirer au pressing et laisse des trous. »	<code>formation_442.md</code> (4-4-2 à plat classique)	<code>rest_defense.md</code> / <code>compacite.md</code> (Principes de défense préventive et compacité)

3. Vision V2 PRO & Guide pour l'Entretien

La Vision V2 PRO : RAG Sémantique & Event Data Quantitatif

- Pour passer à l'échelle industrielle (analyse sur 10 000+ matchs multi-saisons), le projet s'oriente vers un **modèle sémantique et statistique hybride**, découplant et faisant converger les données qualitatives et quantitatives :
- **Données Quantitatives (Event Data)** : Stockage relationnel sous **PostgreSQL** des métriques atomiques (xA, xG, PPDA, coordonnées X/Y des passes/tirs) extraites de façon hebdomadaire par un scraper asynchrone (Playwright) sur FBref/Opta.
 - **Données Qualitatives (Textuelles)** : Indexation vectorielle sous **Qdrant** de comptes-rendus condensés et de fiches de scouting générés par LLM (une fiche ultra-dense par match pour éviter la pollution contextuelle).
 - **Moteur de Récupération Composée** : Traduction dynamique de la question utilisateur en requête SQL pour compiler les stats cumulées, combinée à une recherche de similarité vectorielle Qdrant pour la philosophie tactique. Les deux flux fusionnent dans un prompt orchestré par Gemini.

Feu de Route de Déploiement (Roadmap sur 12 Mois)

Mois 1-2	Mois 3-5	Mois 6-8	Mois 9-12
Base de données Migration PostgreSQL. Modélisation relationnelle (SQLAlchemy). Singleton d'accès unifié PostgreSQL/Qdrant.	Pipeline ETL Scraper Playwright pour FBref. Routine LLM d'auto-résumé des comptes-rendus de match avant vectorisation.	Moteur Hybride Routeur sémantique trend_engine.py (Text-to-SQL + Scan sémantique). Optimisation des temps de réponse (<800ms).	Dashboard UI Radar de performances (xG vs xA vs Pressing), courbes de forme et export PDF de rapports de scouting.

■ Guide d'Entretien : Points Clés à Valoriser

- **Le Pitch (2 minutes)** : « J'ai conçu Football IQ, un copilote tactique hybride RAG pour les clubs. Il ne se contente pas de chercher des documents, il classe les requêtes par intentions, résout le biais de formation grâce à une pondération sémantique sur mesure, et combine les données d'événements (xG, xA) avec l'analyse sémantique. »
- **Justification des Choix Techniques** : Qdrant a été choisi pour sa rapidité de recherche vectorielle et SQLite pour son intégrité relationnelle et sa légèreté dans un MVP. Le fallback local TF-IDF assure que le service reste disponible même sans connexion internet ou sans crédit d'API externe (haute résilience).
- **Storytelling de Résolution de Problème** : Raconter comment la détection du biais de recherche sur le 4-3-3 vs la relance a mené à l'implémentation de la solution algorithmique pondérée. C'est la preuve d'une démarche d'ingénierie rigoureuse basée sur les données.